

## Trabalho 3: Aprendizado de Máquina – Aprendizado Supervisionado

### Fase 1: Análise de Correlação e Regressão Linear

Este trabalho visa entender a natureza da relação linear entre os dados. Faremos a análise de *correlação*, que é utilizada para medir a intensidade de associação de duas variáveis (Relação Linear), e, também a análise de *regressão*, que é utilizada para prever valores de uma variável dados os valores de outra. A correlação foca primeiramente na associação, enquanto a regressão é designada para ajudar a fazer previsões.

Considere os três grupos de dados (datasets) a seguir:

```
x1 = [10;8;13;9;11;14;6;4;12;7;5];  
y1 = [8.04;6.95;7.58;8.81;8.33;9.96;7.24;4.26;10.84;4.82;5.68];  
  
x2 = [10;8;13;9;11;14;6;4;12;7;5];  
y2 = [9.14;8.14;8.47;8.77;9.26;8.10;6.13;3.10;9.13;7.26;4.74];  
  
x3 = [8;8;8;8;8;8;8;8;8;8;19];  
y3 = [6.58;5.76;7.71;8.84;8.47;7.04;5.25;5.56;7.91;6.89;12.50];
```

A melhor maneira para visualizar a relação entre os dados é gerando um Gráfico(Diagrama) de Dispersão (utilize o comando Octave *scatter*). O Gráfico de Dispersão representam o quanto uma variável é afetada por outra.

A correlação mede a direção e intensidade da relação linear. O coeficiente da correlação  $r$  entre as variáveis  $x$  e  $y$  são calculadas com a seguinte equação:

$$r = \frac{\Sigma(x-\bar{x})(y-\bar{y})}{\sqrt{(\Sigma(x-\bar{x})^2 \Sigma(y-\bar{y})^2)}}$$

A reta da regressão é definida por:

$$\hat{y} = \beta_0 + \beta_1 x$$

Onde,

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

$$\beta_1 = \frac{\Sigma(x-\bar{x})(y-\bar{y})}{\Sigma(x-\bar{x})^2}$$

- 1) Implemente duas funções chamadas **correlacao.m** e **regressao.m**. Cada uma deve ter dois vetores Nx1 como entrada, onde N é a dimensão do vetor (no caso de x N=11). A primeira

função deve calcular o coeficiente de correlação  $r$ , e a segunda função deve calcular a regressão, isto é,  $\beta_0$  e  $\beta_1$ .

- 2) Faça um script no Octave chamado **demo.m** onde para cada dataset faça os seguintes comandos:
  - a. Faça um Gráfico de Dispersão (veja função **Scatter**).
  - b. Calcule o coeficiente de correlação.
  - c. Trace a linha da regressão no Gráfico de Dispersão (utilize a função **hold on** para isto)
  - d. Mostre os coeficientes de correlação e regressão no Gráfico de Dispersão (utilize as funções **title** e **num2str**)
  - e. Compare seus resultados com as funções Octave **corr** e **glmfit**.
- 3) Qual dos datasets não é apropriado para regressão linear?

## Fase 2: Análise de Regressão Linear Múltipla

Agora, em vez de uma variável independente  $x$  (por exemplo, quando nós modelamos o preço da casa com base apenas em seu tamanho), vamos considerar múltiplas variáveis independentes  $x_1, x_2, \dots, x_N$ . Com isso, iremos prever preço da casa com base em seu tamanho e número de quartos.

Neste caso, a linha de regressão é:

$$y = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_n x_{in}$$

Onde a Matriz  $X$  é definida como:

$$X = \begin{pmatrix} 1 & X_{11} & X_{12} & \dots & X_{1N} \\ 1 & X_{21} & X_{22} & \dots & X_{2N} \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & X_{m1} & X_{m2} & \dots & X_{mN} \end{pmatrix}$$

Deste modo, podemos definir a linha de regressão de uma forma mais simples:

$$\hat{y} = X^* \beta$$

A expressão para os parâmetros do modelo  $\beta$  é:

$$\beta = (X^t X)^{-1} X^t y$$

Semelhante à fase anterior, você deve implementar a função **regmultipla.m** que calcula os parâmetros  $\beta$  para o dados de entrada  $y$  e  $X$ . Faça um script **rmdemo.m** que faz o seguinte:

- a) Baixe os dados do arquivo **data.mat** (para isso, você pode usar a função **load**). A primeira coluna é o tamanho da casa, a segunda coluna é o número de quartos, e a terceira coluna é o preço da casa.

- Gere uma matriz  $X$  para as variáveis independentes (que são o tamanho da casa e o número de quartos) e o vetor  $y$  da variável dependente (que é o preço).
- Verifique a correlação e a regressão para **Tamanho da casa e Preço** e **Número de quartos e Preço**.
- Faça o gráfico (diagrama) de dispersão dos dados. Neste caso iremos trabalhar com o espaço 3D (verifique a função `scatter3`).
- Trace a linha da regressão no Gráfico de Dispersão (verifique a função `plot3`). Você pode girar este gráfico utilizando a seta de rotação.
- Mostre na figura os coeficientes de correlação entre **Tamanho da casa e Preço** e **Número de quartos e Preço**.
- Calcule o preço de uma casa que tem tamanho de 1650 e 3 quartos. O resultado deve ser igual a 293081.
- Compare seus resultados com a função Octave **regress**. Por favor, tenha muito cuidado com os parâmetros de entrada para esta função.

### Fase 3: Regressão Polinomial - Overfitting

Nesta fase iremos considerar a Regressão Polinomial com uma variável  $x$ . A Regressão Polinomial encaixa uma relação não linear entre o valor de  $x$  e o valor correspondente de  $y$ . Neste caso a fórmula geral da Regressão Polinomial é:

$$y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \dots + \beta_N X^N$$

e podemos definir a matriz  $X$  como:

$$X = \begin{pmatrix} 1 & X_1 & X_1^2 & X_1^3 & \dots & X_1^N \\ 1 & X_2 & X_2^2 & X_2^3 & \dots & X_2^N \\ \vdots & \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & X_m & X_m^2 & X_m^3 & \dots & X_m^N \end{pmatrix}$$

e a linha de regressão pode ser reescrita como:

$$y = X\beta$$

Desta vez, para calcular o valor de  $\beta$  use a função **polyfit**. Você deverá verificar o que acontece quando vamos aumentamos o grau de um polinômio, ou seja, quando consideramos  $N = 1, 2, 3 \dots$

Faça um script **demo\_regressaop.m** que faz o seguinte:

- Baixe o arquivo **data\_preg.mat**. A primeira coluna representa os valores de  $x$  e a segunda coluna representa os valores de  $y$ .
- Faça o Gráfico de dispersão dos dados.
- Use a função **polyfit** para gerar a linha de regressão para  $N = 1$  e trace-o no gráfico de dispersão na cor vermelha (`plot(x, y, 'r')`). (observe que nesta função a numeração coeficiente é invertida!  $\beta_0 = \beta_N$ ,  $\beta_1 = \beta_{N-1}$ ,  $\beta_2 = \beta_{N-2}$ , ...  $\beta_N = \beta_0$ )
- Trace a linha de regressão para  $N = 2$  no gráfico na cor verde.

- e) Trace a linha de regressão para  $N = 3$  no gráfico na cor preta.
- f) Trace a linha de regressão para  $N = 8$  no gráfico na cor amarela.
- g) Calcule o Erro Quadrático Médio (EQM) para cada linha de regressão. Qual é o mais preciso?
- h) Para evitar o overfitting, divida os dados aleatoriamente em Dados de Treinamento e Dados de Teste. Use os primeiros 10% dos dados como conjunto de teste, e o resto como de treinamento.
- i) Repita os passos de **c - f**, mas agora use **apenas os dados de treinamento** para ajustar a linha de regressão.
- J) Repita o passo **g**, mas agora utilize **somente os dados de Teste** para calcular o erro.
- k) Que método é o mais preciso neste caso?

#### Observações:

- Envie um total de 3 funções: **correlacao.m**, **regressao.m**, **regmultipla.m** e 3 scripts: **demo.m**, **rmdemo.m**, **demo\_regressaop.m** (todas com comentários do que foi feito), e responda as perguntas nos comentários de cada script.
- Coloque o nome dos integrantes do grupo na primeira linha das funções e scripts.
- Envie apenas uma versão para todo o grupo, especificando também os nomes de todos os outros colegas.
  - T3\_Aluno1\_Aluno2\_Aluno3.zip